Willkommen zum Seminar





© 2021 anderScore GmbH

Apache Kafka - Event Streaming mit Java

Vorstellung



Jan Lühr (M.Sc. Computer Science)

- Senior Software Engineer
- Schwerpunkte
 - Pragmatic Architect
 - Integration und Migration
 - Web / Mobile Engineering
 - Clean Code
 - Trainings, Artikel, Vorträge
 - Network- and Security-Techniques
 - IT-Trainer
- Java, Spring, JEE, Kafka, Android, Microservices,...



Unternehmen



- Standort: Köln (mit Rheinblick...)
- Individuelle Softwareentwicklung
- Confluent Partner
- Consulting und Festpreis
- Gesamter Application Life Cycle
- Konferenzen und Artikel
- Öffentliche Trainings



- Technologien
 - JEE, Spring
 - Vaadin, Wicket, Angular, React, Vue
 - Docker, Kubernetes, Apache Kafka
 - ...
- Goldschmiede@anderScore



Apache Kafka – Event Streaming mit Java

02.12. - 03.12.21

Jan Lühr



Agenda



Begrüßung

- 1. Einführung
- 2. Paradigmen und Funktionsweise
- 3. Komponenten
- 4. Client-Implementierung
- 5. Analyse und Transformation
- 6. Broker Operations
- 7. Best Practices
- 8. Ausblick



Lektion 1 - Einführung

Inhalt und Ziel



Workshop

- Einführung in grundlegende Kafka-Konzepte
- Überwindung von Einstiegshürden
- Funktionen und Features mit Aufgaben erarbeiten

Zielgruppe

 Softwareentwickler, Architekten und DevOps (m/w/x) mit guten Java-Kenntnissen

Voraussetzungen

- Gute Java Kenntnisse
- Sicherheit im Umgang mit einer IDE (hier: IntelliJ Community Edition)

Zeitplan



Beginn	09:00 Uhr
Kaffeepause	ca. 10:30 Uhr
Mittagspause	12:00 bis 13:00 Uhr
Ende	16:00 Uhr

Remote Training



- Video-Konferenz über Zoom
 - Bildschirmfreigabe für Folien
 - Breakout Rooms f
 ür Übungen
 - Lautsprecher + Mikrophon benötigt, Kamera empfehlenswert
- Entwicklung: Remote Desktop Protocol (RDP) zur GFU
 - Praktische Übungen
 - Ubuntu VM
 - Aufschaltung über Zoom möglich
- Material auf GitHub

https://github.com/anderscore-gmbh/kafka-21.12

Remote Training



Vereinbarungen

- Pausen
 - Gemeinsam zu vorgegebenen Zeiten
 - Individuell während der Übungen
- Erreichbarkeit Dozent
 - Zoom (Chat, Mikrophon)
 - E-Mail
 - Kamera aus: gerade nicht anwesend bzw. ansprechbar
- Regeln
 - Mikrophon möglichst aus (Hintergrundgeräusche)
 - Bei Fragen: "Hand heben" oder Chat
 - Wenn Übung fertig, selbst in Hauptsession zurückkehren

Material



- Kafka Quickstart
 - https://kafka.apache.org/quickstart
- Kafka Cheat Sheet
 - https://github.com/lensesio/kafka-cheat-sheet
- Kafka E-Book
 - https://www.confluent.io/resources/kafka-the-definitive-guide

Vorstellung



Jetzt sind Sie dran!

- Name
- Vorwissen
- Erwartungen
- Themenwünsche



Ihre Umgebung



- OpenJDK 11
- IntelliJ Community Edition
- Docker
- Docker Compose
- Maven
- Spring
- Kafkacat

Aufgabe 0 - Hello World mit Kafkacat



Aufgabenstellung:

- Installieren Sie kafkacat auf Ihrem System
- Senden Sie eine Nachricht an broker-1.k.anderscore.com: 9092 Topic: HelloWorld
- Konsumieren Sie alle Nachrichten des Topics und geben Sie diese aus

Hinweise:

- Ubuntu / Debian (vorinstalliert): apt-get install kafkacat
- Nachricht senden:

```
echo "Hallo Welt" | kafkacat -b broker-1.k.anderscore.com -t HelloWorld
```

Nachricht konsumieren:

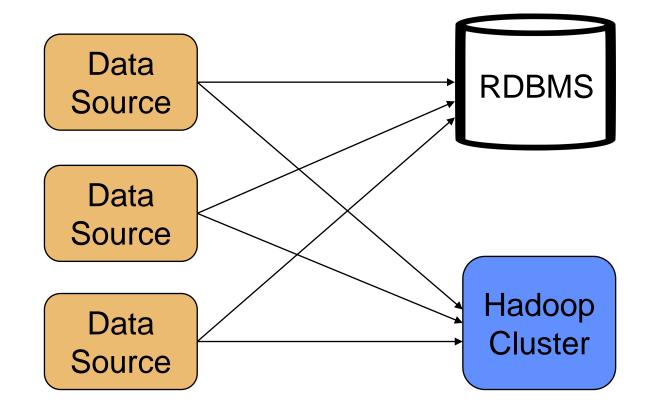
kafkacat -b broker-1.k.anderscore.com -t HelloWorld

Lektion 2 - Paradigmen und Funktionsweise von Kafka

Was ist Kafka?



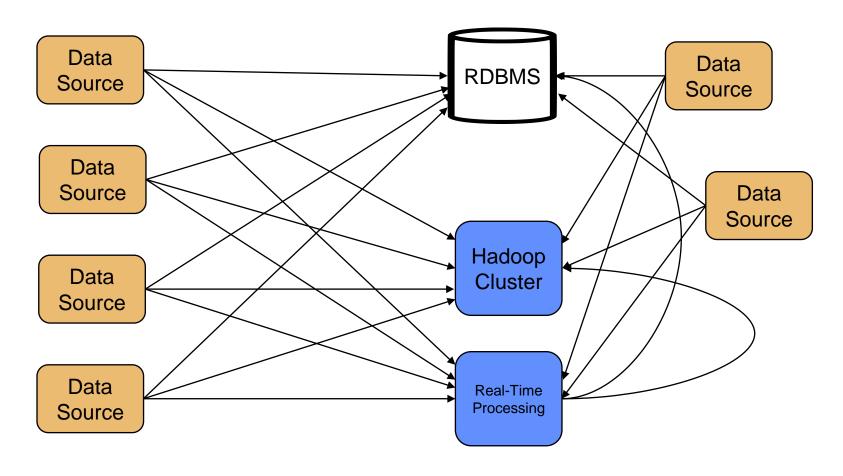
Einfache Datenverteilung:



Was ist Kafka?



Komplexe Datenverteilung:



Motivation für Kafka



Motivation

- Komplexe Datenverteilung bewältigen
- Batch-Verarbeitungsprozess verbessern
- Zeitnahe Verarbeitung ermöglichen

Ansatz

- Middleware f
 ür persistente Logs / Streams
- Ähnlich zu MQTT und Message Queueing

Ziele von Kafka

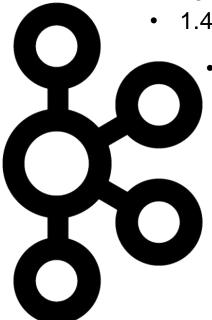
- Pipelines vereinfachen
- Data Stream Handling

Anstatt Batch Processing -> Stream Processing

Apache Kafka



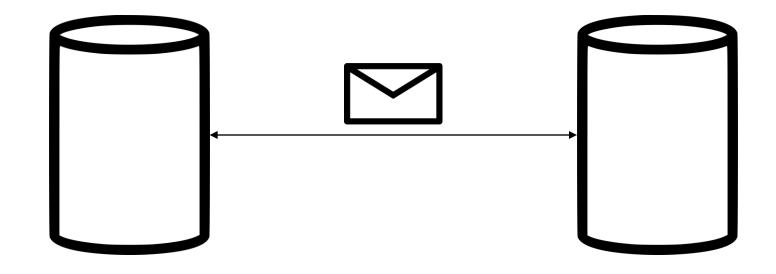
- LinkedIn (2010)
 - Teil der Core-Architektur
 - 1.4 Milliarden Nachrichten pro Tag



- Genutzt von:
 - IBM, Spotify, Uber, Hotel.com, Twitter...
- Use Cases:
 - Event Verarbeitung (quasi realtime)
 - Log Aggregation
 - Metriken & Analyse
 - Messaging / µService Kommunikation
- Keine Realtime- bzw. Echtzeitverarbeitung (Werbeversprechen; im Sinne von Reordering Queues)

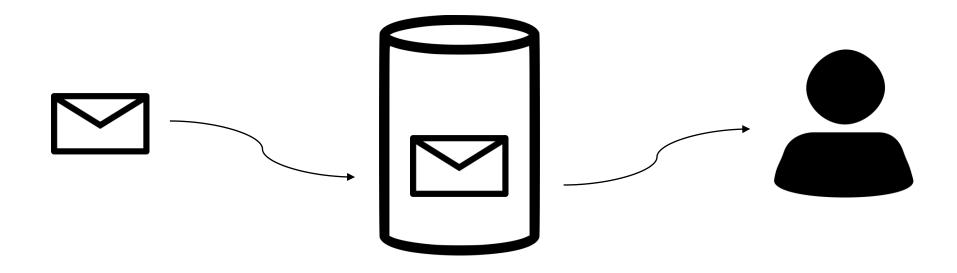
Synchrone Kommunikation



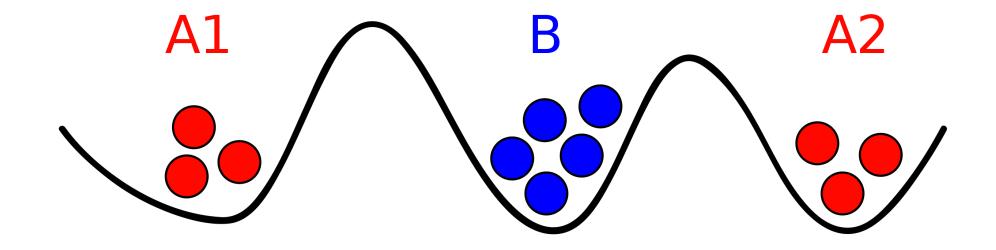


Asynchrone Kommunikation

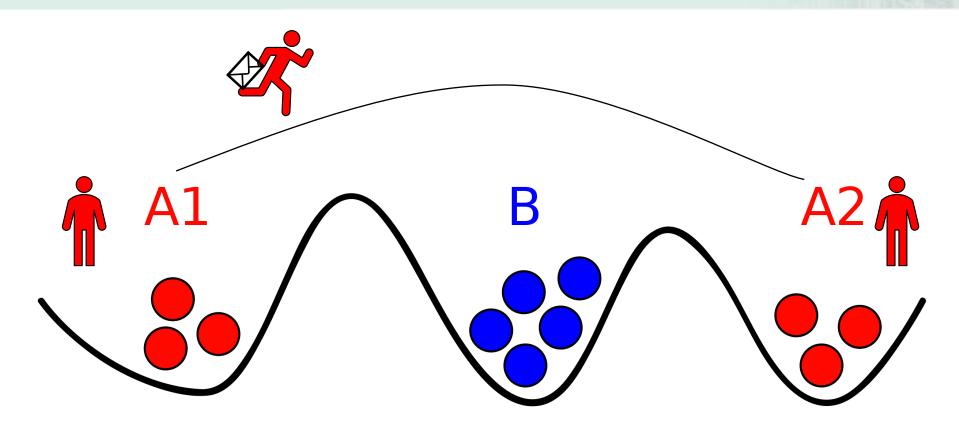




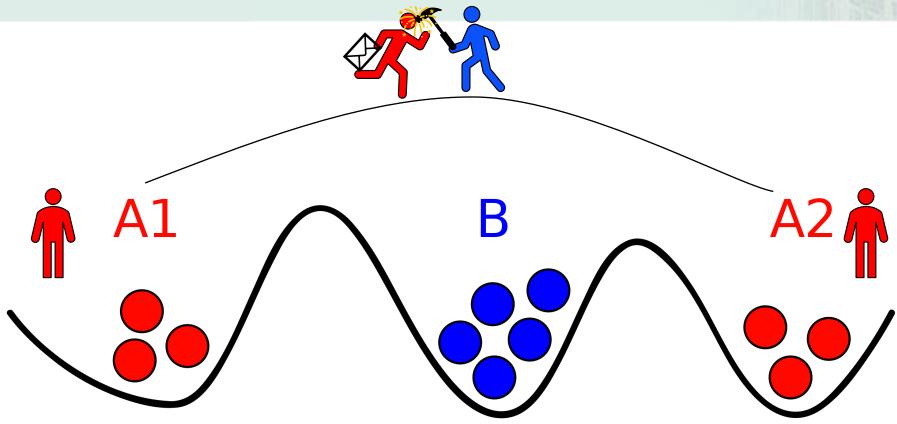




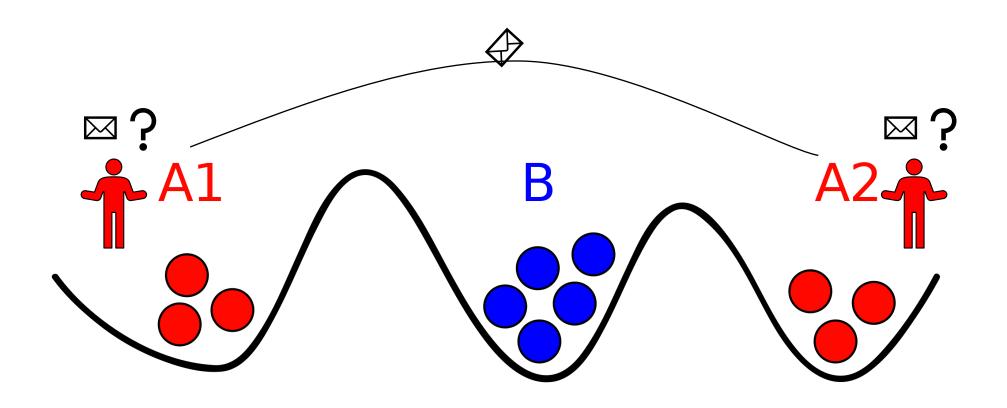












Idempotenz



Definition:

Eine Operation, welche mehrfach hintereinander ausgeführt das gleiche Ergebnis wie bei einer einzigen Ausführung liefert.

https://de.wikipedia.org/wiki/Idempotenz

Semantik beim Aufruf



Was passiert bei einem Fehler?

- At least once
 - Mindestens ein Mal: Risiko von Duplikaten
- At most once
 - Maximal ein Mal: kein Neuversuch beim Fehlschlag
- Exactly once
 - Genau ein Mal: in Praxis schwer zu erreichen

At Least Once Beispiel: Print Server



At Least Once



Situation: Druckfehler / Toner leer: Ausdruck zu hell!

- 1. Fehler wird behoben
- 2. Alle Seiten in der Warteschlange werden gedruckt
- 3. ... sehr viel Papier

At Most Once Beispiel: Print Server



At Most Once



Situation: Druckfehler / Toner leer: Ausdruck zu hell!

- 1. Fehler wird behoben
- 2. Keine Seite in der Warteschlage wird gedruckt
- 3. ... hin und her laufen.

Exactly Once Beispiel: Print Server



Exactly Once



Situation: Druckfehler / Toner leer: Ausdruck zu hell

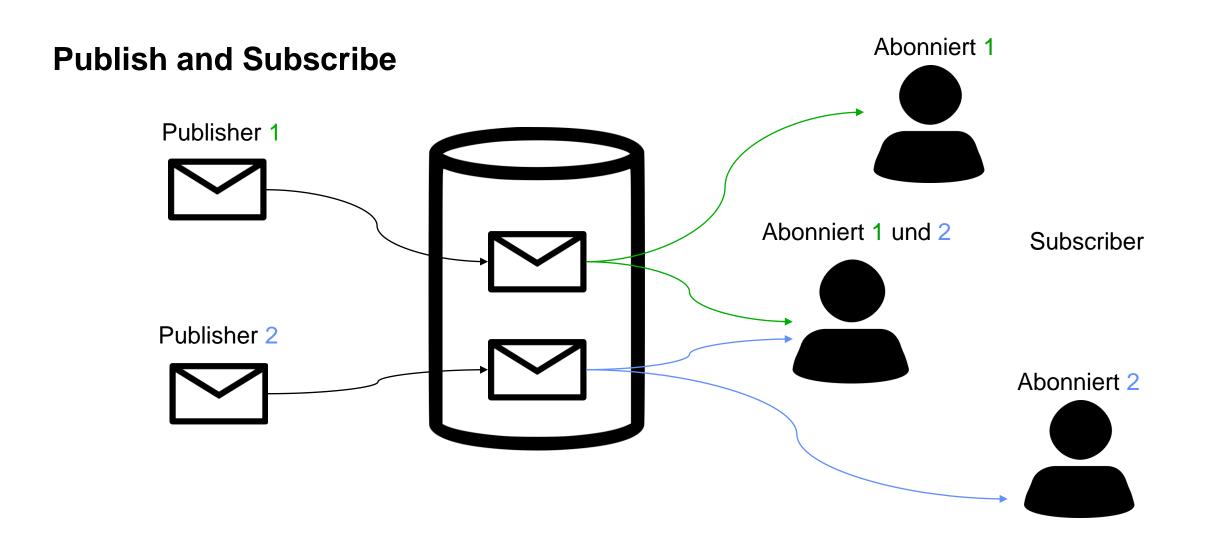
- 1. Fehler wird behoben
- 2. Genau die zu hellen Seiten werden gedruckt
- 3. ... Perfekt ©

Woher weiß der Drucker, welche Seiten zu hell sind?

- Idee: Seitennummer am Bedienfeld eingeben
- Im Allgemeinen: schwer umsetzbar
- Idee *auch bei Kafka*: Stand der Verarbeitung im Ergebnis speichern

Paradigmen in Kafka





Paradigmen in Kafka



Active Polling

Konzept:

- Es wird nicht automatisch an alle Subscriber gesendet (vgl. Observer Pattern)
- Subscriber senden zyklisch Anfragen
- Existiert neuer Inhalt, wird er als Antwort zurückgeliefert

Paradigmen in Kafka



Event Sourcing

Konzept:

- Veränderung eines Zustandes = Event
- Nach Empfang neuer Daten werden alte nicht gelöscht
- Neue Events werden kontinuierlich im Event Store an alte angehängt
- Kafka: Retention Policy

Zweck:

- Kein Informationsverlust
- Analysemuster
- Macht Kafka zu einem Hybrid aus Datenbank und Messaging System

Aufgabe 1 – Hello Kafka World



- Kafka Quickstart oder
- Docker Broker

Aufgabenstellung Quickstart:

Laden Sie das aktuelle Kafka Release aus:

http://kafka.apache.org/quickstart

- Starten Sie das Kafka Environment in der Linux Shell
- Legen Sie einen Topic an
- Schreiben Sie einige Nachrichten in das Topic
- Lesen Sie die Nachrichten aus

Aufgabe 1.1 - Hinweise Quickstart



Hinweise:

Download Link Kafka:

https://dlcdn.apache.org/kafka/3.0.0/kafka_2.13-3.0.0.tgz

\$ tar -xzf kafka_2.13-3.0.0.tgz \$ cd kafka_2.13-3.0.0

Zookeeper starten:

\$ bin/zookeeper-server-start.sh config/zookeeper.properties

Kafka Broker starten:

\$ bin/kafka-server-start.sh config/server.properties

Aufgabe 1.1 - Hinweise Quickstart



Topic erzeugen:

\$ bin/kafka-topics.sh --create --topic HelloWorld --bootstrap-server localhost:9092

Topic prüfen:

\$ bin/kafka-topics.sh --describe --topic HelloWorld--bootstrap-server localhost:9092

Topic: HelloWorld PartitionCount: 1 ReplicationFactor: 1 Configs:

Topic: HelloWorld Partition: 0 Leader: 0 Replicas: 0 Isr: 0

Aufgabe 1.1 - Hinweise Quickstart



Nachricht in das Topic schreiben:

\$ bin/kafka-console-producer.sh --topic HelloWorld --bootstrap-server localhost:9092 This is my first event This is my second event

Nachricht aus Topic auslesen:

\$ bin/kafka-console-consumer.sh --topic HelloWorld --from-beginning --bootstrap-server localhost:9092 This is my first event This is my second event

Aufgabe 1.2 - Docker



Aufgabenstellung Docker:

- Setzen Sie einen eigenen Kafka Broker mit Docker gemäß folgendem Tutorial auf:
 - https://medium.com/big-data-engineering/hello-kafka-world-the-complete-guide-to-kafka-with-docker-andpython-f788e2588cfc
 - Starten Sie die Kafka Shell
- Legen Sie einen Topic an
- Initialisieren Sie einen Producer, der eine "Hello World" Nachricht in den Topic schreibt
- Initialisieren Sie einen Consumer von einem anderen Kafka Terminal, welcher Nachrichten aus dem Topic liest

Aufgabe 1.2 - Hinweise Docker



Hinweise:

Klonen Sie das kafka-docker Projekt und initialisieren Sie die Umgebung mit docker-compose:

https://github.com/wurstmeister/kafka-docker

> git clone https://github.com/wurstmeister/kafka-docker.git
> cd kafka-docker

Updaten Sie KAFKA_ADVERTISED_HOST_NAME in 'docker-compose.yml',
Ändern Sie es zum Beispiel zu: 172.17.0.1
> sudo vim docker-compose.yml
> sudo docker-compose up -d

Optional: Scalen Sie das Cluster indem Sie mehr Broker hinzufügen (Wird eine zookeeper Instanz starten)
> sudo docker-compose scale kafka=3

Sie können die laufenden Prozesse mittels folgendem Befehl checken:
> sudo docker-compose ps

Zerstören sie das Cluster wenn Sie damit fertig sind:
> sudo docker-compose stop

Aufgabe 1.2 - Hinweise Docker



Kafka Shell

Mit folgendem Befehl hochfahren

```
> ./start-kafka-shell.sh <DOCKER_HOST_IP/KAFKA_ADVERTISED_HOST_NAME>
# Wie im Beispiel:
> ./start-kafka-shell.sh 172.17.0.1
```

Einen 'Hello' Topic anlegen

In der Kafka Shell:

```
> $KAFKA_HOME/bin/kafka-topics.sh --create --topic test \
--partitions 4 --replication-factor 2 \
--bootstrap-server `broker-list.sh`

> $KAFKA_HOME/bin/kafka-topics.sh --describe --topic test \
--bootstrap-server `broker-list.sh`
```

Aufgabe 1.2 - Hinweise Docker



Hello Producer

• Producer initialisieren und eine Nachricht in den Topic schreiben:

```
> $KAFKA_HOME/bin/kafka-console-producer.sh --topic=test \
--broker-list=`broker-list.sh`
>> Hello World!
>> I'm a Producer writing to 'hello-topic'
```

Hello Consumer

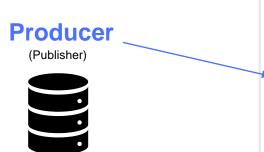
 Consumer von einem anderen Kafka Terminal initialisieren, welcher Nachrichten vom Topic liest:

```
> $KAFKA_HOME/bin/kafka-console-consumer.sh --topic=test \
--from-beginning --bootstrap-server `broker-list.sh`
```

Lektion 3 – Komponenten

Kafka Komponenten: Producer





- Teil einer Anwendung
- Senden Daten an den Kafka Cluster
- Sharding der Messages (Partitionieren)
 - Über Hash Key oder Round Robin
 - Alternativ auch über eigene Strategie
- Für Load Balancing und Semantic Partitioning
- Anbindung über:
 - Nativ: Java, C/C++, Python, Go, .Net, JMS
 - Rest (Confluent)
- Weiterhin existieren Implementierungen für viele andere Sprachen

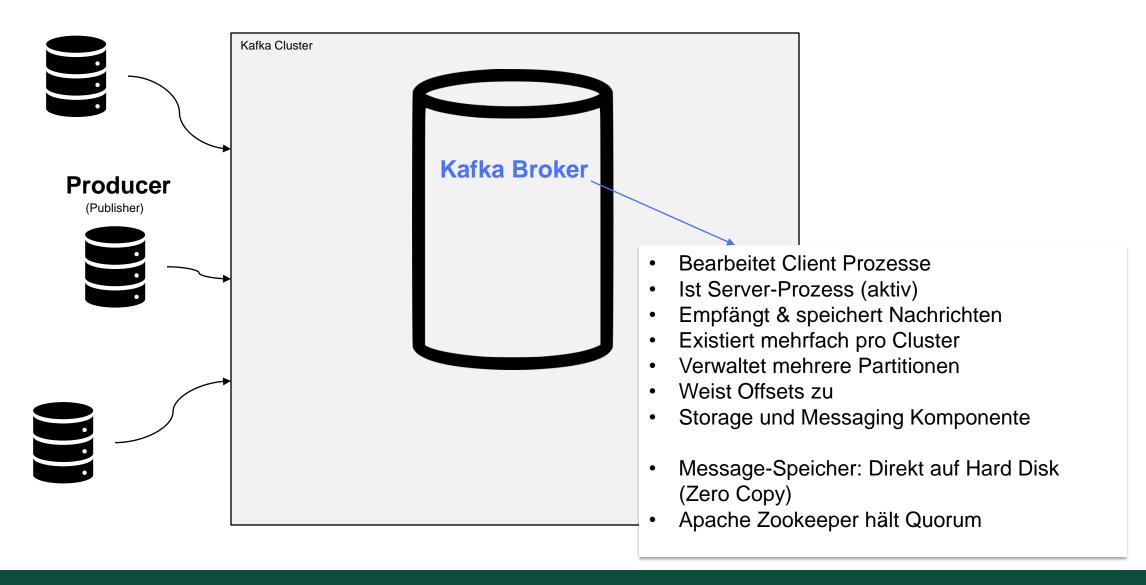
Kafka Komponenten: Cluster





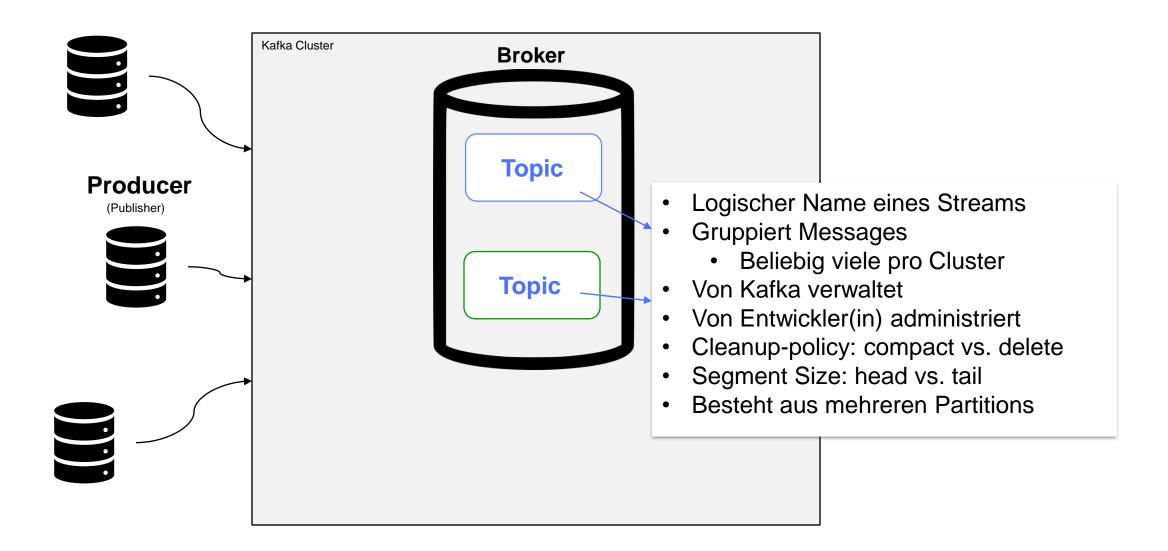
Kafka Komponenten: Broker





Kafka Komponenten: Topic





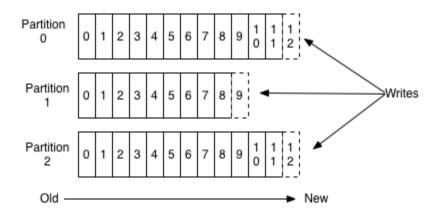
Anatomie eines Topics



Aufbau:

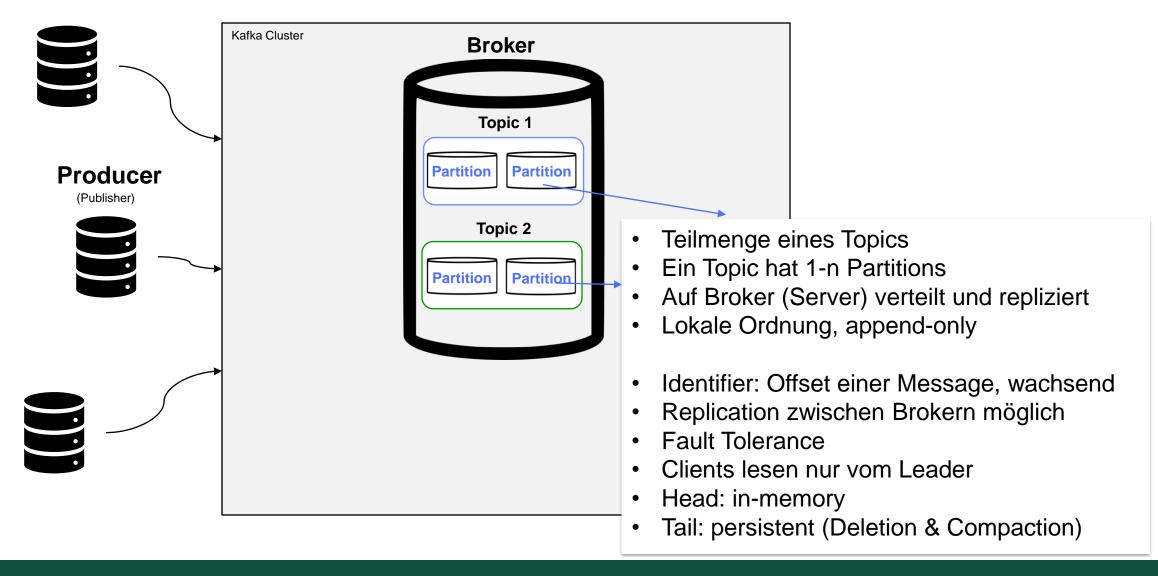
- Cluster besteht aus 1-n Brokern
- Broker haben Topics
- Topics haben 1-m Partitions
 - Clients lesen nur vom Leader
 - Drift konfigurierbar
- Partitions haben eine wachsende Anzahl an Offsets
- Lokale Ordnung innerhalb einer Partition

Anatomy of a Topic



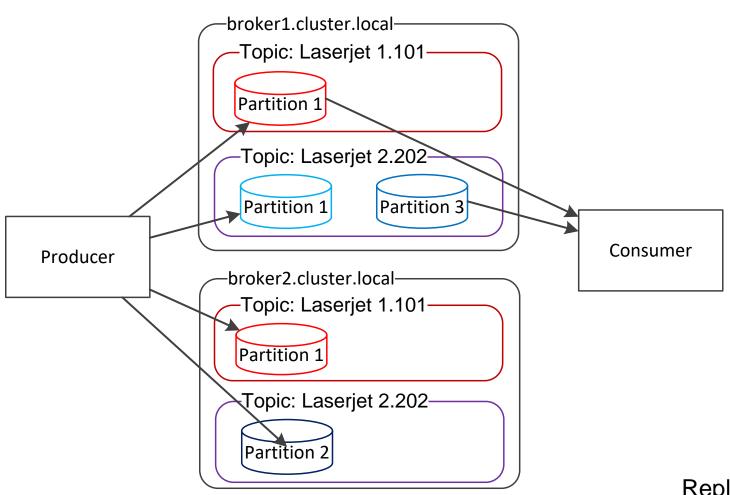
Kafka Komponenten: Partition





Partitionen: Printer Beispiel



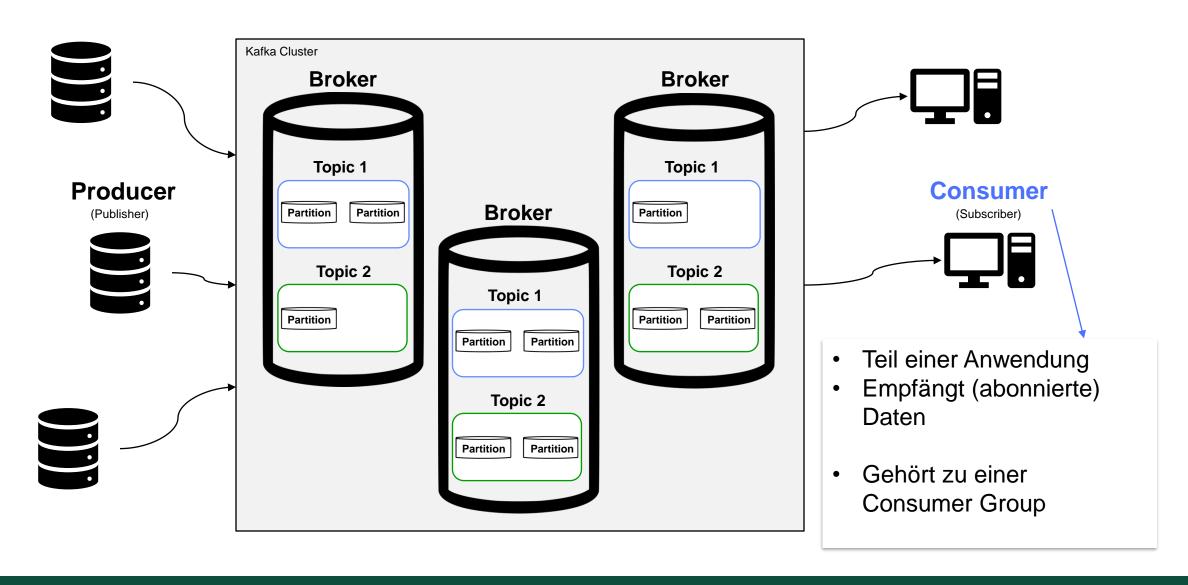


Repliziert: Laserjet 1.101

Sharding: Laserjet 2.202

Kafka Komponenten: Consumer





Kafka Komponenten: Consumer



Abruf von Messages via pull, single-threaded

Consumer Offset

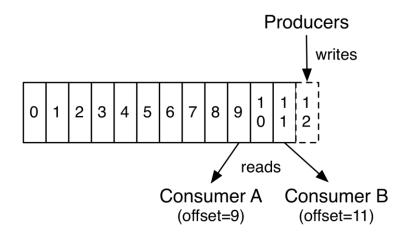
- Nächste zu lesende Nachricht
- Pro Partition
- Speicher: Spezielles Topic (oder extern)
- Commit: automatisch (default: 5 sec Obacht!) oder manuell

Semantik:

- At least once: Nachricht bearbeiten danach Commit
- At most once: Commit, danach Nachricht bearbeiten
- Exactly once: Offset im Zielsystem speichern

Verschiedene Consumer

- Gleichzeitiges Lesen möglich
- Default: Alle Nachrichten im Topic an alle Consumer
- Spezialfall: Consumer Group

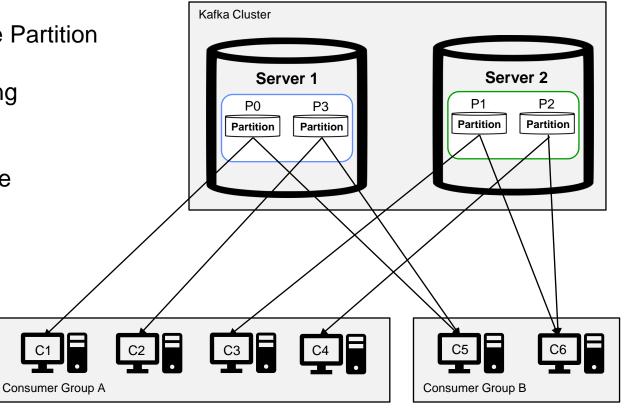


https://docs.confluent.io/platform/current/clients/consumer.html

Kafka Komponenten: Consumer Groups



- Gruppierung: Consumer Group
 - Mehrere Consumer kombinieren -> Consumer Group
 - Jeder Consumer bearbeitet nur Subset der Partitionen
 - Eindeutige Group ID
 - Jeder Consumer in einer Group braucht eigene Partition
 - Ein Subset von Partitionen
 - Automatisches Error-Handling & Load-Balancing
- Scaling
 - Maximal ein Consumer pro Partition pro Gruppe
 - #Consumer ≤ #Partitions
 - #Partition ändern: Schwer möglich
 - Besser: Neues Topic bei Release-Wechsel (API-Versionierung)



Zookeeper



Was ist **Zookeeper**?

- Open Source von Apache
- Ermöglicht verteilte Koordination
- Kümmert sich um Konfigurationsinformationen
- Bietet verteilte Synchronisation

Besteht aus drei oder fünf Servern im Quorum

- Quorum:
 - Eine replizierte Gruppe von Servern in der gleichen Applikation nennt man Quorum
 - Im replicated mode haben alle Server im Quorum eine Kopie der gleichen Config Datei

Zookeeper in Kafka



Kafka Broker nutzen **Zookeeper** für:

- Cluster Management
- Fehlerfindung und Wiederherstellung
- Speicherung von Access Control Lists (ACL)

Aufgabe 2 – Topics und Partitionen



Aufgabenstellung:

- Erstellen Sie ein Topic mit 2 Partitionen auf dem Broker, welchen Sie in Aufgabe 1 eingerichtet haben
 - Alternativer Broker: broker-1.k.anderscore.com
- Welche Funktion und Auswirkung haben die Parameter:
 - a) segment.ms **und** segment.bytes
 - b) cleanup.policy = delete (oder compact)
 - c) retention.ms **oder** retention.bytes
 - d) min.cleanable.dirty.ratio
- Schreiben Sie die Zahlen 0...42 in das Topic und lesen Sie sie daraus.
 Wie sind die Zahlen geordnet?

Aufgabe 2 - Hinweise



Hinweise:

Verwenden Sie die Kafka Command Line Tools um das Topic anzulegen

Topic erzeugen:

bin/kafka-topics.sh --bootstrap-server localhost:9092 --create \
--topic myTopic --partitions 2 --replication-factor 1

Aufgabe 2 - Hinweise



Nachricht senden:

for zahl in `seq 0 42`; do echo \$zahl | bin/kafka-console-producer.sh \
--broker-list localhost:9092 --topic myTopic; done.

Hinweis: Schneller geht's auch mit kafkacat statt kafka-console-producer.sh, da kein JVM-Process pro Iteration erzeugt wird – kafka-console-producer.sh bringt jedoch mehr Optionen

Nachricht Lesen:

bin/kafka-console-consumer.sh --bootstrap-server localhost:9092 \
--from-beginning --topic myTopic

Lektion 4 – Client Implementierung

"Hello Kafka" in Java



Java APIs für Kafka

Java Producer API

- Kafka Client, welcher Datensätze zum Kafka Cluster published
 - Thread Safe
 - Dependency Injection Scope: Singleton
 - Pufferung bei Verbindungsverlust
 - Automatische Retries möglich (Vorsicht: Reordering!)

Java Consumer API

- Kafka Client, welcher Datensätze aus einem Kafka Cluster konsumiert
 - Transparenz bei Fehlern von Brokern
 - Passt sich an Migrationen von Partitionen im Cluster an
 - Interagiert mit Broker und erlaubt Zugriff auf dessen Consumer Groups

Java Producer API



Erstellung eines Producers:

Klasse

public class KafkaProducer<K,V>

Wichtige Eigenschaften und Senden

Producer Eigenschaften



bootstrap.servers

- Liste an Broker host/port Paaren für eine initiale Verbindung zum Cluster
- key.serializer / value.serializer
 - Klassen zur Serialisierung von Keys bzw. Values
 - Müssen Serializer Interface implementieren

acks

- Anzahl an Bestätigungen (Acknowledgements), welche der Producer benötigt, bevor der Request fertig ist
- acks = 0: Producer wartet nicht auf Bestätigungen vom Server
- acks = 1: Producer wartet, bis der Datensatz auf den lokalen Log geschrieben wurde
- acks = all: Producer wartet, bis alle in-sync Replikate das Erhalten der Datensätze bestätigt haben

Nachricht an Kafka senden



- Die send () Methode ist non-blocking
 - Gibt Datensatz in einen Buffer von wartenden Datensätzen über und gibt sofort ein Return zurück
 - Effizienz: Batched einzelne Datensätze zusammen
 - Falls nötig kann mit .send(record).get() ein block geforced werden

```
ProducerRecord<String, String> record = new ProducerRecord<String, String>("my-topic", "myKey", "myValue");

Future<RecordMetadata> metadata = producer.send(record);
producer.close();
```

Retries:

- Wie oft ein Send bei einem Fehler wiederholt wird
- Kann zu Änderung in der Reihenfolge der Nachrichten führen!
- Anzahl der Connections kann angepasst werden

```
retry.backoff.ms=100
retries=600

# default ist 5
set max.in.flight.requests.per.connection=1
```

Buffer beim Versenden



Default Linger:

- Buffer sendet sofort, auch bei ungenutztem Space
- Um die Anzahl an Requests zu verringern, kann Wartezeit konfiguriert werden
- Erhöht Effizienz bei minimaler Latenz

größer als 0 linger.ms = 1

Buffer Größe:

- Gesamtmenge an Speicher, welcher dem Producer für den Buffer zu Verfügung gestellt wird
- Wenn der Buffer voll ist, werden Send Requests geblockt (TimeoutException)

buffer.memory max.block.ms

Callbacks



Reaktion auf Fehler:

Fehler: Metadata ist null

Kein Fehler: Exception ist null

Java Consumer API



Erstellung eines Consumers:

Klasse

```
public class KafkaConsumer<K,V>
```

Wichtige Eigenschaften und Polling

```
Properties props = new Properties();
props.setProperty("bootstrap.servers", "localhost:9092");
props.setProperty("group.id", "test");
props.setProperty("enable.auto.commit", "true");
props.setProperty("auto.commit.interval.ms", "1000");
props.setProperty("key.deserializer", "org.apache.kafka.common.serialization.StringDeserializer");
props.setProperty("value.deserializer", "org.apache.kafka.common.serialization.StringDeserializer");

KafkaConsumer<String, String> consumer = new KafkaConsumer<>(props);
consumer.subscribe(Arrays.asList("foo", "bar"));
while (true) {
    ConsumerRecords<String, String> records = consumer.poll(Duration.ofMillis(100));
    for (ConsumerRecord<String, String> record : records)
        System.out.printf("offset = %d, key = %s, value = %s%n", record.offset(), record.key(),
record.value());
}
```

Consumer Eigenschaften



- bootstrap.servers
 - Liste aus Broker hosts/ports Paaren für eine initiale Verbindung zum Cluster
- key.deserializer / value.deserializer
 - Klassen zur Deserialisierung von Keys bzw. Values
 - Müssen Deserializer Interface implementieren
- group.id
 - Zeigt an, zu welcher Consumer Group der Consumer gehört
- enable.auto.commit
 - Bei true triggered der Consumer offset commits

Properties props = new Properties(); props.setProperty(setting, value);

Nachricht aus Kafka lesen



- Die poll () Methode gibt alle verfügbaren Nachrichten zurück
 - Bis zu der maximalen Größe per Partition

default 1048576 bytes max.partition.fetch.bytes

- Eine zu hohe Anzahl an Partitionen kann extreme Mengen an Daten zurückgeben
 - Gesamtmenge von Datensätzen in einem einzelnen Poll kann reduziert werden (Chunking)

max.poll.records

Aufgabe 3 – Producer und Consumer



Aufgabenstellung:

- Erzeugen Sie ein neues Java Projekt und binden Sie den Kafka Client ein
- Verbinden Sie sich mit Ihrem Kafka Broker
- Implementieren Sie einen Consumer: Lesen Sie alle Nachrichten aus dem Topic "HelloWorld" aus
- Geben Sie die Nachrichten auf der Konsole aus
- Implementieren Sie einen Producer

Aufgabe 3 - Hinweise



- Im einfachsten Fall können Sie Kafka-Events ohne weitere Frameworks konsumieren.
- Hierzu müssen die entsprechenden Bibliotheken in das Projekt angebunden werden.

Erstellen Sie ein neues Maven Projekt z.B. mit:

```
mvn archetype:generate -DgroupId=gs -DartifactId=kafka \
-DarchetypeArtifactId=maven-archetype-quickstart \
-DinteractiveMode=false
```

- Fügen Sie dann die Maven Dependency der Datei pom.xml hinzu
- Nutzen Sie die folgenden Klassen:

org.apache.kafka.clients.consumer.KafkaConsumer org.apache.kafka.clients.producer.KafkaProducer

Einbindung in Spring Boot



Spring for Kafka

- Version 2.7 seit 2016
- Basiert auf Kernkonzepten von Spring (z.B. DI, Annotationen, Templates)
- Wird verwendet, um Kafka basierte Messaging Lösungen zu entwickeln
- Bietet Template f
 ür High-Level Abstraktion f
 ür das Senden von Messages
- Bietet Support f
 ür Message-driven POJOs
- Es kann plain Java zum Versenden und Empfangen von Messages genutzt werden
- Java mit Konfiguration
- Oder am simpelsten mit Spring Boot

Kafka mit Spring Boot - Beispiel



Dependencies

- spring-kafka JAR und alle seine Dependencies
- Am einfachsten mit Maven

```
<dependency>
    <groupId>org.springframework.kafka</groupId>
    <artifactId>spring-kafka</artifactId>
    <version>2.6.5</version>
</dependency>
```

Spring Boot Beispiel:

- Anwendung sendet 3 Nachrichten an ein Topic
- Nachrichten werden empfangen
- Anwendung wird beendet

Spring Boot - Beispiel



Voreinstellungen

- Es wird Group Management benutzt, um Topics und Partitions Consumern zuzuordnen
- Hierfür muss eine Gruppe erstellt werden:

spring.kafka.consumer.group-id=foo

- Der Container könnte nach dem Verstand der Nachrichten starten
- Es muss ein Offset eingestellt werden, um sicher zu gehen, dass die neue Consumer Group die Nachrichten auch bekommt:

spring.kafka.consumer.auto-offset-reset=earliest

Spring Boot - Beispiel



```
@SpringBootApplication
public class Application implements CommandLineRunner {
    public static Logger logger = LoggerFactory.getLogger(Application.class);
    public static void main(String[] args) {
        SpringApplication.run(Application.class, args).close();
   @Autowired private KafkaTemplate<String, String> template;
   private final CountDownLatch latch = new CountDownLatch(3);
   @Override
   public void run(String... args) throws Exception {
       this.template.send("myTopic", "foo1");
       this.template.send("myTopic", "foo2");
       this.template.send("myTopic", "foo3");
       latch.await(60, TimeUnit.SECONDS);
       logger.info("All received");
   @KafkaListener(topics = "myTopic")
   public void listen(ConsumerRecord<?, ?> cr) throws Exception {
       logger.info(cr.toString());
       latch.countDown();
```

Aufgabe 4 – Kafka mit Spring Boot



Aufgabenstellung:

- Erstellen Sie ein Spring Boot Projekt
- Binden Sie die Kafka Bibliotheken ein und konfigurieren Ihren Broker auf Port 9092
- Konsumiren Sie das Topic "Hallo Welt" und geben Sie es auf der Konsole aus
- Senden Sie eine Nachricht an das Topic

Aufgabe 4 - Hinweise



- **Properties**: group-id und auto-offset-reset anpassen
- Wie ein neues Spring-Boot-Projekt anzulegen ist, wird hier beschrieben:
 - https://spring.io/guides/gs/spring-boot/
 - https://start.spring.io



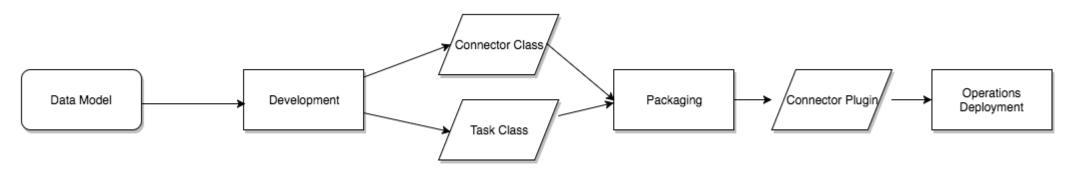
Lektion 5 – Analyse und Transformation

Kafka Connect



Anbindung von externen Systemen an Kafka

- Beispiel: Oracle RDB
- Verschiedene Konnektoren in Confluent Platform enthalten.
- Connector: Job bzw. Plugin für Kafka Cluster
- Task: Logik zur Durchführung des Datenaustausches (stateless)
- Workers: Laufende Prozesse f
 ür Connectors und Tasks (standalone vs. distributed)
- Converters: Konverter zwischen Kafka und Datenquelle bzw. Datensenke (z.B. JsonConverter)
- **Transforms**: Anpassung von Nachrichten von oder zu einem Connector (z.B. Filter)
- Dead Letter Queue: Behandlung von Connector Fehlern (auch für Consumer relevant!)



Quelle: https://docs.confluent.io/platform/current/connect/concepts.html#:~:text=handles%20connector%20errors-,Connectors,defined%20in%20a%20connector%20plugin.

Kafka Streams



Kafka ist eine Streaming Plattform

- Stream = kontinuierliches, ununterbrochenes, updatendes Set
- Streams von Datensätzen publishen und abonnieren
 - ähnelt einer Message Queue
 - oder: einem Enterprise Messaging System
- Speichern von Datensatz-Streams
 - Fehlertolerante Weise
- Verarbeiten von Datensätzen
 - sobald diese auftreten

Anwendung von Streams

- Real Time Streaming Datenpipelines
 - Zuverlässiger Austausch von Daten zwischen Systemen oder Anwendungen
- Real Time Streaming Anwendungen
 - Auf Daten Streams reagieren oder diese transformieren

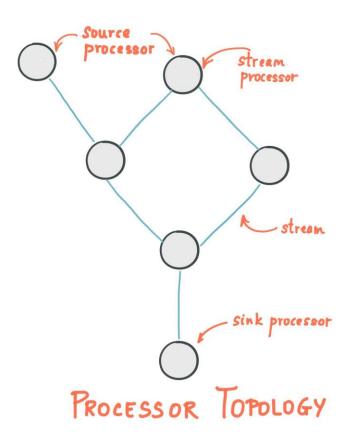
Kafka Streams



- Einfache Anwendung durch Java Library
- Ähnlich zu Spark Streaming, Apache Storm und Co.
- KafkaStreams DSL (map, flatMap, count, ...) vs. low-level Processor API
- Abstraktion: KStream, KTable, ksqlDB

```
public class WordCountApplication {
   public static void main(final String[] args) throws Exception {
       Properties props = new Properties();
        props.put(StreamsConfig.APPLICATION ID CONFIG, "wordcount-application");
        props.put(StreamsConfig.BOOTSTRAP SERVERS CONFIG, "kafka-broker1:9092");
       props.put(StreamsConfig.DEFAULT_KEY_SERDE_CLASS_CONFIG, Serdes.String().getClass());
        props.put(StreamsConfig.DEFAULT_VALUE_SERDE_CLASS_CONFIG, Serdes.String().getClass());
       StreamsBuilder builder = new StreamsBuilder();
       KStream<String, String> textLines = builder.stream("TextLinesTopic");
       KTable<String, Long> wordCounts = textLines
            .flatMapValues(textLine -> Arrays.asList(textLine.toLowerCase().split("\\\+")))
            .groupBy((key, word) -> word)
            .count(Materialized.<String, Long, KeyValueStore<Bytes, byte[]>>as("counts-store"));
       wordCounts.toStream().to("WordsWithCountsTopic", Produced.with(Serdes.String(), Serdes.Long()));
       KafkaStreams streams = new KafkaStreams(builder.build(), props);
        streams.start();
```

Quelle: https://kafka.apache.org/documentation/streams/



Quelle: https://kafka.apache.org/20/documentation/streams/core-concepts

KStream vs. KTable



- KStream
 - Abstraktion des Record Streams
 - Alle Messages werden als Insert betrachtet
- KTable
 - Abstraktion des Changelog Streams
 - Messages werden als Insert bzw. Update (sog. "Upsert") betrachtet
- Beispiel: Summation
 - Nachricht 1: {id: 'apple', value: 1}
 - Nachricht 2: {id: 'apple', value: 2}
 - Ergebnis:
 - KStream: 3 (Summe der Records)
 - KTable: 2 (Update für Nachricht mit ID 'apple')

Aufgabe 5 – Kafka Streams



Beschreibung

- Kafka-Streams erlauben die "Echtzeit"-Auswertung und Transformation von Daten, die auf Kafka-Topics veröffentlicht werden
- In der Dokumentation wird die Verwendung zur Z\u00e4hlung der Worte im Stream verwendet: https://kafka.apache.org/documentation/streams/

Aufgabenstellung:

- Starten Sie das Beispiel aus der Dokumentation
- Zählen Sie die Wörter im Topic "Hello World" auf dem Broker broker-1.k.anderscore.com (Port 9092)

Aufgabe 5 - Hinweise



Hinweise:

- Erzeugen Sie die Projektstruktur wie in Aufgabe 4
- Für Kafka-Streams wird eine weitere Maven Dependency benötigt:

```
<dependency>
<groupId>org.apache.kafka</groupId>
<artifactId>kafka-streams</artifactId>
<version>2.0.0</version>
</dependency>
```

- Die Streams aktualisieren sich, wenn Sie Nachrichten senden.
- Das Codebeispiel schreibt das Ergebnis in den Stream WordsWithCountsTopic, den Sie konsumieren müssen.
- Die Ergebnisse erscheinen innerhalb des eingestellten Intervalls per default müssen Sie ein paar Sekunden warten.

ksqIDB

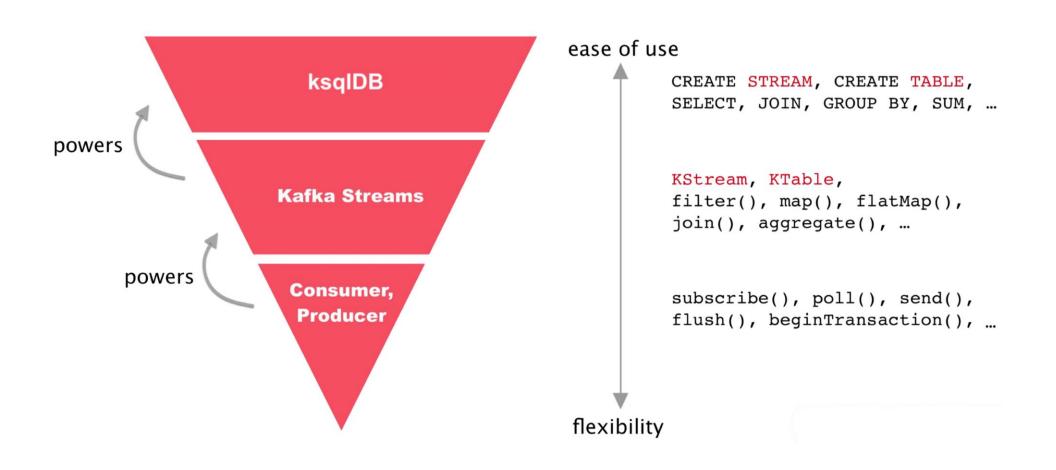


Event Streaming Database

- Hilft beim Erstellen komplexer Stream Processing Anwendungen mit Kafka
- Abfragen, Lesen, Schreiben und Verarbeiten von Daten
- Deklarative Definition von Tabellen, Streams und Konnektoren
- Dynamische Joins
- Lightweight SQL Syntax
- SQL-like Interface
- Runtime: ksqlDB Engine
- Community Component von Confluent
- Alternative / Aufbau zu Kafkas Stream API
- Besser für:
 - Streaming ETL Pipelines
 - Reaktion auf kontinuierliche Real-Time Business Requests
 - Anomalien erkennen

ksqIDB





Quelle: https://docs.ksqldb.io/en/latest/concepts/ksqldb-and-kafka-streams

ksqIDB - Beispiel



ksqIDB:

```
CREATE STREAM fraudulent_payments AS

SELECT fraudProbability(data) FROM payments WHERE fraudProbability(data) > 0.8

EMIT CHANGES;
```

Kafka Streams:

```
public class FraudFilteringApplication {
   StreamsBuilder builder = new StreamsBuilder();
   KStream<String, Payment> fraudulentPayments = builder
        .stream("payments-topic")
        .filter((customer ,payment) -> payment.getFraudProbability() > 0.8);
        .to("fraudulent-payments-topic");

Properties config = new Properties();
   config.put(StreamsConfig.APPLICATION_ID_CONFIG, "fraud-filtering-app");
   config.put(StreamsConfig.BOOTSTRAP_SERVERS_CONFIG, "kafka-broker1:9092");
   new KafkaStreams(builder.build(), config).start();
}
```

Nach: https://docs.ksqldb.io/en/latest/concepts/ksqldb-and-kafka-streams

Lektion 6 – Broker Operations

Kafka Broker Konfigurieren



Config Files

- Jeder Broker hat eine Config Datei
 - .property file extension
 - Kann in der Datei oder programmatisch angepasst werden
 - Nutzt Key / Value Paare

Beispiel:

/usr/local/kafka/config/server.properties

Essentielle Konfiguration



broker.id

- ID des Servers
- Bekommt ID automatisch, wenn nicht explizit gesetzt
- Vermeidung von Konflikten zwischen automatisch und explizit gesetzten IDs:
 - reserved.broker.max.id +1

log.dirs

- Verzeichnis der log Daten
- Wenn nicht genutzt, wird stattdessen das Verzeichnis in log.dir benutzt

zookeeper.connect

- Definiert den Zookeeper connection string
 - hostname:port
- Um Verbindung zu anderen Zookeeper Nodes zu ermöglichen, falls eine down ist:
 - hostname1:port1, hostname2:port2...

Broker Konfiguration



- advertised.host.name
- advertised.listeners
- advertised.port
- auto.create.topics.enable
- auto.leader.rebalance.enable
- background.threads
- compression.type
- control.plane.listener.name
- delete.topic.enable
- host.name
- leader.imbalance.check.interval.seconds
- leader.imbalance.per.broker.percentage
- listeners
- log.flush.interval.ms
- log.flush.offset.checkpoint.interval.ms
- log.flush.start.offset.checkpoint.interval.ms
- log.retention.bytes/hours/minutes/ms
- log.roll.hours/ms
- log.roll.jitter.hours /ms
- log.segment.bytes
- log.segment.delete.delay.ms

- message.max.bytes
- min.insync.replicas
- num.io.threads
- num.network.threads
- num.recovery.threads.per.data.dir
- num.replica.alter.log.dirs.threads
- offsets.metadata.max.bytes
- offsets.commit.required.acks
- offsets.topic.segment.bytes
- port
- queued.max.requests
- quota.consumer.default
- quota.producer.defaults
- replica.fetch.min.bytes
- request.timeout.ms
- socket.receive.buffer.bytes
- socket.request.max.bytes
- transaction.max.timeout.ms
- unclean.leader.election.enable
- zookeeper.connection.timeout.ms
- zookeeper.max.in.flight.requests
- zookeeper.session.timeout.ms
- Gesamte Liste: https://kafka.apache.org/documentation/#brokerconfigs

Updaten der Broker Konfiguration



Live Update

- Einige Configs können ohne Broker Restart geändert werden
 - ready-only: nur mit Neustart
 - per-broker: dynamisch f
 ür jeden Broker einzeln
 - cluster-wide: dynamisch gesamtes Cluster oder einzelne Broker

Beispiel Live Update:

- Broker id 0
- Anzahl der Log Cleaner Threads

> bin/kafka-configs.sh --bootstrap-server localhost: 9092 --entity-type brokers --entity-name 0 --alter --add-config log.cleaner.threads=2

Topics verwalten



Overrides können auch später mit add-config konfiguriert werden

• Im folgenden Beispiel wird die max.message.bytes upgedated:

> bin/kafka-configs.sh --bootstrap-server localhost:9092 --entity-type topics --entity-name my-topic --alter --add-config max.message.bytes=128000

Overrides überprüfen mit --describe:

> bin/kafka-configs.sh --bootstrap-server localhost:9092 --entity-type topics --entity-name my-topic --describe

• Override entfernen mit --alter --delete-config:

> bin/kafka-configs.sh --bootstrap-server localhost:9092 --entity-type topics --entity-name my-topic --alter --delete-config max.message.bytes

Topics verwalten: Einstellungen



Topic Level Einstellungen: Beispiele

- cleanup.policy
- compression.type
- delete.retention.ms
- file.delete.delay.ms
- flush.messages
- flush.ms
- follower.replication.throttled.replicas
- index.interval.bytes
- leader.replication.throttled.replicas
- min./max.compaction.lag.ms
- max.message.bytes
- message.format.version
- message.timestamp.difference.max.ms
- Komplett: https://kafka.apache.org/documentation/#topicconfigs

- message.timestamp.type
- min.cleanable.dirty.ratio
- min.insync.replicas
- preallocate
- retention.bytes
- retention.ms
- segmentet.bytes
- segment.index.bytes
- segment.jitter.ms
- segment.ms
- unclean.leader.election.enable
- message.downconversion.enable

Topics konfigurieren, anlegen und verwalten



Topic Konfiguration

- Relevante Konfiguration
 - Server Default
 - Per-Topic Override

Der Override kann beim Erstellen eines Topics in der Kafka Shell eingestellt werden

- --config
- Eine oder mehrere Einstellungen

```
> bin/kafka-topics.sh --bootstrap-server localhost:9092 --create --topic my-topic --partitions 1 \
--replication-factor 1 --config max.message.bytes=64000 --config flush.messages=1
```



Lektion 7 – Best Practices

Best Practices



Producer

- Automatische Retries möglichst abschalten (Reordering)
- acks = all für "Konsistenz über Verfügbarkeit" (vgl. CAP Theorem)
- Mehrere Bootstrap Server angeben (Fehlertoleranz)

Consumer

- Nicht zu viele Daten auf einmal pollen (Netzwerklast, OutOfMemoryError)
- Auto-Commit beachten und möglichst abschalten
- Topics mit Consumer Offsets richtig konfigurieren (Compaction und Deletion!)
- At-least-once-Semantik meist beste Wahl
- Mehrere Bootstrap Server angeben (Fehlertoleranz)

Nach: https://media.ccc.de/v/froscon2018-2213-apache_kafka_lessons_learned

Best Practices



Broker

Defaults setzen und bei Bedarf überschreiben (Fehlervermeidung)

Topics

- Deletion vs. Compaction **fachlich** entscheiden
- retention.ms wirkt nur bei Deletion, max.cleanable.dirty.ratio nur bei Compaction
- Automatisiert anlegen (z.B. Skript)
- Richtwert: ~ 10 bis 30 Partitionen pro Topic

Streams

Dead Letter Queue vorsehen (z.B. Topic)

Nach: https://media.ccc.de/v/froscon2018-2213-apache_kafka_lessons_learned

Lektion 8 – Ausblick

Microservice Architektur

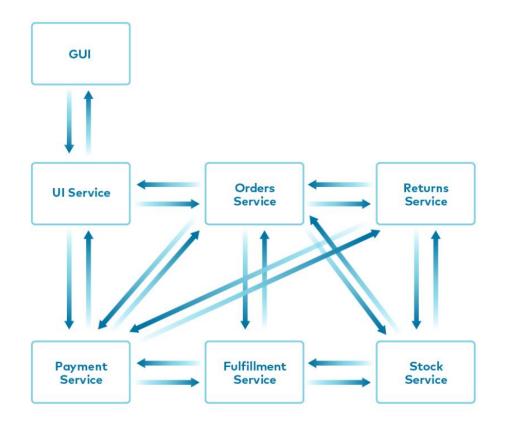


Microservices:

- Bequeme Abstraktion f
 ür Wiederbenutzbarkeit
- Kleine Services sind einfach austauschbar
- Potential f
 ür bessere Skalierbarkeit und Fehlertoleranz
- Komplette Unabhängigkeit von Services

Beispiel:

- Simples Business System in Microservice Architektur
- Event-basiert



Quelle: WP Microservices in the Apache Kafka Ecosystem Confluent 2017

Microservices mit Kafka

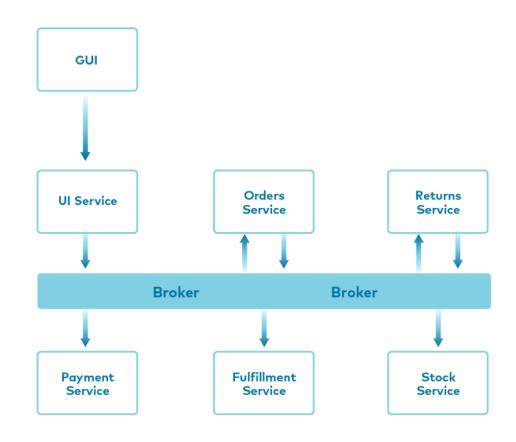


Microservice Environment

- Event-basiert
- Request / Response basiert
- Hybrider Ansatz:
 - Service Discovery
 - Synchrone Vorgänge
 - Asynchrone, Event-basierte Flows
 - Aber auch:
 - Anpassbarkeit
 - Skalierbarkeit

Praxisbeispiel:

- Asynchroner eMail Service mit Kafka Streams
- Order und Payment Stream joinen
- Ergebnis zu einem Lookup Table von Kunden joinen
- E-Mail zu jedem resultierenden Touple versenden



Quelle: WP Microservices in the Apache Kafka Ecosystem Confluent 2017

Apache Avro - Serialization



Apache Avro

- Data Serialization System (& RPC, Container)
- Vergleichbar mit: Thrift, Protocol Buffers
- Aktuell: 1.10.2 (März 2021)
- Bindings: Java, Pyhton, C, C++, C#, JavaScript, ... (3rd party)

Teil des Hadoop Projekts

- Serialization Format für persistente Daten
- Wire Format f
 ür Nodes und Clients

Schema für Daten in JSON

- Getrennt von den Nutzdaten
- Code-Generatoren (code-first, contract-first)



Apache Avro – Beispiel für Schemata



```
"namespace": "example.avro",
"type": "record",
"name": "User",
"fields": [
          {"name": "name", "type": "string"},
          {"name": "favorite_number", "type": ["int", "null"]},
          {"name": "favorite_color", "type": ["string", "null"]}
]
```

Quelle: https://en.wikipedia.org/wiki/Apache_Avro

Apache Avro – Integration mit Kafka



- Confluent Schema Registry (OpenSource)
 - Historisierung, Java & RESTful API, Migration
 - Kein Transport mit den Daten (Performance)
 - Persistenz: Kafka-Topic
 - Command Line Client
- Avro als wire-format?
 - Einheitliches Schema für Daten zwischen Systemen
 - Pro:
 - Integration (confluent platform)
 - Contra:
 - XML & JSON deutlich weiter verbreitet



Aufgabe 6 - Avro



Beschreibung:

- Austausch von Nachrichten zwischen zwei Services über Kafka
- Serialisierung und Deserialisierung über Avro mit JSON-Schemata
- Generierung von Java Klassen aus Metadaten
- Die Confluent Platform enthält eine Avro Schema Registry, mit der Schemas unternehmensweit verwaltet werden können.
- Die OpenSource-Ausgabe der Confluent-Platform ist auf broker-2.k.anderscore.com installiert.
- Weitere Infos: https://docs.confluent.io/current/schema-registry/docs

Aufgabe 6 - Avro



Aufgabenstellung:

- Unter folgendem Link liegt ein Producer, welcher Personendaten (SteuerID, Name, Vorname) sendet: https://github.com/anderscore-gmbh/kafka-21.12/tree/master/Aufgabe6-Producer
- Implementieren Sie einen Consumer, welcher die Daten de-serialisiert und auf der Konsole ausgibt.

Schemata:

http://broker-2.k.anderscore.com:8081/subjects

http://broker-2.k.anderscore.com:8081/schemas/ids/1

http://broker-2.k.anderscore.com:8081/schemas/ids/2

Aufgabe 6 - Hinweise



Hinweise:

- Verwenden Sie den Consumer aus Aufgabe 4 als Vorlage
- Die Schemata können Sie aus dem Producer übernehmen oder aus der Registry laden.
- Beachten Sie die pom.xml des Producers zu Abhängigkeit und Generator-Konfiguration
- Simulieren Sie einen Tippfehler: Benennen Sie das Feld firstName in fristName um und generieren
 Sie den Avro-Code für den Consumer erneut. Was passiert beim Start?
- Tipp: Ändern Sie die Consumer Group bei Bedarf
- Ein Beispiel für den Consumer finden Sie unter:

https://github.com/anderscore-gmbh/kafka-21.12/tree/master/Aufgabe6-Producer